

Функциональная, статистическая и корреляционная зависимость

2

Рассмотрим систему двух случайных величин $\{X, Y\}$.

Эти случайные величины **могут быть независимыми**:

$$f(x, y) = f_1(x) \cdot f_2(y) \quad . \quad (5.1)$$

В противном случае между ними может быть:

функциональная зависимость:

$$y = g(x) \quad .$$

статистическая зависимость:

$$\begin{aligned} \varphi(x / y) &= f(x, y) / f_2(y) \\ \phi(y / x) &= f(x, y) / f_1(x) \end{aligned} \quad (5.2)$$

Одним из видов (частным случаем) статистической зависимости является **корреляционная зависимость**.

Корреляционная зависимость, корреляционный момент, коэффициент корреляции

3

Корреляционной называют статистическую зависимость двух случайных величин, при которой изменение значения одной из случайных величин приводит к изменению математического ожидания другой случайной величины.

$$\begin{aligned} M(X / y) &= q_1(y) \\ M(Y / x) &= q_2(x) \end{aligned} \quad (5.3)$$

Функции (5.3) называют функциями регрессии.

Корреляционный момент:

$$\mu_{xy} = M \{ [x - M(X)] \cdot [y - M(Y)] \} \quad (5.4)$$

Коэффициент корреляции:

$$r_{xy} = \frac{\mu_{xy}}{\sigma_x \sigma_y} \quad (5.5)$$

Корреляционная зависимость, коэффициент корреляции

Для коэффициента корреляции справедливо соотношение:

$$|r_{xy}| \leq 1 \quad (5.6)$$

Случайные величины X и Y называют коррелированными, если их корреляционный момент или (что тоже самое) их коэффициент корреляции отличен от нуля. В противном случае эти величины некоррелированы.

Если случайные величины X и Y коррелированы, то они зависимы.

Обратное предположение в общем случае неверно. То есть, если случайные величины X и Y некоррелированы, то они могут быть, как независимыми, так и зависимыми.

Корреляционная зависимость, коэффициент корреляции

Можно представить эти утверждения в наглядной форме:

X и Y коррелированы \Rightarrow СВ X и Y зависимы

X и Y независимы \Rightarrow СВ X и Y некоррелированы

Если случайные величины X и Y коррелированы и обе функции регрессии Y на X и X на Y линейны, то говорят, что X и Y связаны линейной корреляционной

зависимостью. В частности, это имеет место если двумерная случайная величина $\{X, Y\}$ распределена нормально. Коэффициент корреляции, как известно, служит мерой тесноты линейной зависимости между случайными величинами X и Y . При $|r_{xy}| = 1$ эта зависимость становится функциональной.

Корреляционная таблица

Пусть имеется выборка двумерной случайной величины $\{X, Y\}$. Ее значения удобно представлять в виде так называемой корреляционной таблицы. Например,

Y	X				n_y
	10	20	30	40	
0,4	5	—	7	14	26
0,6	—	2	6	4	12
0,8	3	19	—	—	22
n_x	8	21	13	18	$n = 60$

Статистическая оценка коэффициента корреляции

Значение \bar{r}_{xy} - статистической оценки r_{xy} - коэффициента корреляции можно вычислить по формуле:

$$\bar{r}_{xy} = \frac{\sum_{i=1}^{K_y} \sum_{j=1}^{K_x} n_{ij} y_i x_j - N \bar{x}_6 \bar{y}_6}{NS_x S_y} \quad (5.7)$$

При $N > 50$ в случае нормального распределения системы случайных величин $\{X, Y\}$ для оценки значения r_{xy} можно использовать соотношение:

$$\bar{r}_{xy} - 3 \frac{1 - \bar{r}_{xy}^2}{\sqrt{N}} \leq r_{xy} \leq \bar{r}_{xy} + 3 \frac{1 + \bar{r}_{xy}^2}{\sqrt{N}} \quad (5.8)$$

Вычисление выборочного коэффициента корреляции

При вычислении выборочного коэффициента корреляции необходимо вычислить $\sum_{i=1}^{K_y} \sum_{j=1}^{K_x} n_{ij} y_i x_j = \sum_{j=1}^{K_x} y_i \sum_{i=1}^{K_y} n_{ij} x_j = \sum_{j=1}^{K_x} x_j \sum_{i=1}^{K_y} n_{ij} y_i$.
Это удобно производить в табличной форме:

	X				$X_i = \sum_{j=1}^{K_x} n_{ij} x_j$		$y_i X_i$
Y							
		3			7		
			15			49	
1		5			7		64
	5			7			
			9			28	
5		3			4		37
	15			20			
			12			14	
8		4			2		26
	32			16			
$Y_j = \sum_{i=1}^{K_y} n_{ij} y_i$		52			43		457
$x_j Y_j$		156			301	457	

Доверительный интервал для выборочного коэффициента корреляции

Распределение \bar{r}_{xy} при определенных условиях можно удовлетворительно аппроксимировать нормальным законом. Однако при увеличении интенсивности корреляционной связи распределение \bar{r}_{xy} становится все более асимметричным.

С помощью преобразования Фишера перейдем к случайной величине Z :

$$\bar{z} = 0.5 \ln \frac{1 + \bar{r}_{xy}}{1 - \bar{r}_{xy}} = 1.1513 \lg \frac{1 + \bar{r}_{xy}}{1 - \bar{r}_{xy}} \quad (5.9)$$

Доверительный интервал для выборочного коэффициента корреляции

Распределение z при неограниченном возрастании объема выборки асимптотически нормальное со значением СКВО, равным:

$$\text{I} \quad \bar{\sigma}_z = \frac{1}{\sqrt{N-3}} \quad (5.10)$$

В результате доверительный интервал для r_{xy} генеральной совокупности с доверительной вероятностью γ определяют по следующей схеме:

1. По формуле (5.9) вычисляют выборочное значение \bar{z} ;
2. По формуле (5.10) вычисляют значение $\bar{\sigma}_z$;

Доверительный интервал для выборочного коэффициента корреляции

3. Доверительный интервал для генерального значения представляется в виде:

$$\text{I} \quad (\bar{z} - \lambda(\gamma)\bar{\sigma}_z, \bar{z} + \lambda(\gamma)\bar{\sigma}_z), \quad (5.11)$$

где значение $\lambda(\gamma)$ должно удовлетворять условию:

$$\Phi[\lambda(\gamma)] = \frac{\gamma}{2} \quad (5.12)$$

4. Для пересчета интервала (5.11) в доверительный интервал для коэффициента корреляции с тем же значением γ необходимо воспользоваться обратным преобразованием Фишера:

$$r = th(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}} = \frac{e^{2z} - 1}{e^{2z} + 1} \quad (5.13)$$

Проверка гипотезы о значимости выборочного коэффициента корреляции

Пусть имеется выборка объема N значений двумерной нормально распределенной случайной величины $\{X, Y\}$ и вычислено значение выборочного коэффициента корреляции $\bar{r}_{xy} \neq 0$. Поскольку \bar{r}_{xy} является случайной величиной, то это еще не значит что r_{xy} - коэффициент корреляции для генеральной совокупности тоже отличен от нуля.

Возникает необходимость проверить гипотезу $H_0 : r_{xy} = 0$. Альтернативной будет гипотеза $H_1 : r_{xy} \neq 0$.

Если основная гипотеза H_0 отвергается, то это означает, что выборочный коэффициент корреляции \bar{r}_{xy} значимо отличается от нуля (значим). В противном случае – \bar{r}_{xy} незначим.

Проверка гипотезы о значимости выборочного коэффициента корреляции

В качестве критерия проверки статистической гипотезы о значимости выборочного коэффициента корреляции можно принять случайную величину:

$$T = \frac{\bar{r}_{xy} \sqrt{N-2}}{\sqrt{1-\bar{r}_{xy}^2}} \quad (5.14)$$

При справедливости нулевой гипотезы H_0 случайная величина T распределена по закону Стьюдента с $k=N-2$ степенями свободы.

Критическая область для данного критерия двусторонняя.

Проверка гипотезы о значимости выборочного коэффициента корреляции

Проверка гипотезы осуществляется по стандартной схеме:

1. По формуле (5.14) вычисляется значение $T_{набл}$;
2. По заданному уровню значимости α и значению k из таблицы определяется значение $t_{крит}(\alpha, k)$;
3. Если $|T_{набл}| \leq t_{крит}(\alpha, k)$ - нет оснований отвергать гипотезу H_0 .
4. Если $|T_{набл}| > t_{крит}(\alpha, k)$ - основная гипотеза H_0 с выборочными данными и должна быть отвергнута.